言葉のルールで仕分けるロボットアーム vol.5

Physical AI 講座 2026 応用編1 最終課題レポート：判断モデル Claude Fable 5.1・GPT-6 Astra・Jev の比較

2026年11月1日

1. 概要

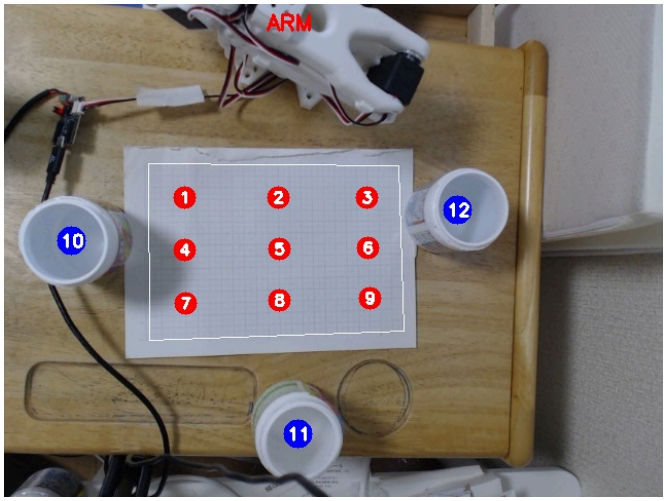
日本語で書いた仕分けルール（例：「暖色の物は左へ、寒色の物は右へ」）に従って、机の上の物体を SO-101 アームで3つのカップに仕分けるシステムを作った。物体の検出は真上のカメラと色の処理で行い、どの物をどこへ運ぶかの判断をモデルに任せた。アームの動きは学習させず、人が教えた姿勢を補間して作った。

vol.5 では、判断を担うモデルを3つ用意し、同じ日に同じ条件で比べた。文章を生成する LLM の Claude Fable 5.1 と GPT-6 Astra、そして選択肢ごとの確率を返す判断専用モデルの Jev（TypeSafe）である。検出とアームの動きは共通で、判断だけを替えた。

項目	Claude Fable 5.1	GPT-6 Astra	Jev 1.14
ルール判断の一括評価（12ルール・108回）	答えが決まる 197 件すべて正解	197 件すべて正解	197 件すべて正解
判断1回の時間（一括評価の平均）	5.3 秒	5.3 秒	0.18 秒
一括評価 108 回の費用	3.38 ドル	定額の利用枠（1回 約 15,000 トークン）	0.004 ドル
実機の通し試験（3ルール × 3個、同じ日）	9個中 9個	9個中 9個	9個中 9個
信号機のルールでピンクを	「赤」とみなして左へ	「赤」とみなして左へ	「赤」とみなさず右へ

- 動画：2分53秒（3つのモデルを並べた比較の場面は2倍速。音は撮影時の音と BGM）
- コード：https://github.com/Indy-ai86/so101-language-sorter

2. しくみ



真上のカメラの画像。赤の 1〜9 が姿勢を教えた点、青の 10〜12 が置き場

処理は4段階で、どれも学習を使わない。

1. **検出**：真上のカメラ（C920）で1枚撮り、色の範囲で物体を切り出す。方眼紙の枠の四隅で画像と机の座標（cm）を対応づけ、物体ごとに色・形・大きさ・位置を出す。
2. **判断**：検出結果を JSON にして、ルール文と一緒に判断モデルに渡す。モデルは物体ごとに置き場（左・中央・右）と、その確からしさを返す。画像は渡さず、検出結果の文字情報だけで判断させている。
3. **動作**：方眼の 3×3 の点で、リーダーアームを使って「掴む姿勢」を教えた。物体の位置に応じて、周りの4点の関節角を双線形補間して掴む姿勢を作る。逆運動学は使っていない。
4. **記録**：撮影した状態、判断、実機の成否を、試行ごとにファイルへ残す。集計は evaluate.py で再現できる。

3つの判断モデルへの問い方。 指示文・ルール文・物体の一覧は、3つとも同じ文面で渡した。違うのは呼び方と答えの受け取り方である。

	Claude Fable 5.1	GPT-6 Astra	Jev（TypeSafe System One）
呼び方	Claude Code のヘッドレス実行（`claude -p`）	Codex CLI のヘッドレス実行（`codex exec`）	HTTP API（`POST /v1/systemone`）
答えの形	JSON スキーマで、全物体の置き場と自信（0〜1）を一度に返させる	同左	物体1個につき「左・中央・右」の選択式の質問を1つ立て、3つの確率を返させる
確からしさ	モデルが自分で申告する自信	同左	各置き場の確率。選んだ置き場の確率を使う

Fable と Astra は、それぞれのコーディング用 CLI をツールなしで呼び、出力を JSON スキーマで固定した。Astra は Codex がエージェント用の前置きを毎回付けるため、1回の入力が約 15,000 トークンになった（Jev は約 900 トークン）。Jev は文章を生成せず、質問ごとに選択肢の確率だけを返す。同じ場面の全物体についての質問を、1回の呼び出しでまとめて送った。

3. 工夫した点

判断と動作を分けた。 「どこへ運ぶか」は判断モデル、「どう掴むか」は教えた姿勢の補間、と役割を分けた。判断は実機なしでまとめて評価でき、実機の失敗と判断の失敗を切り分けられる。vol.5 では、この分け方のおかげで判断モデルだけを差し替えて比べられた。判断先は `--backend fable|astra|jev` で切り替える。

確からしさを返させた。 ルールが物体に当てはまるか曖昧なとき、モデルは低い値を返す。`--min-conf` を付けると、値が低い物は運ばずに残す。

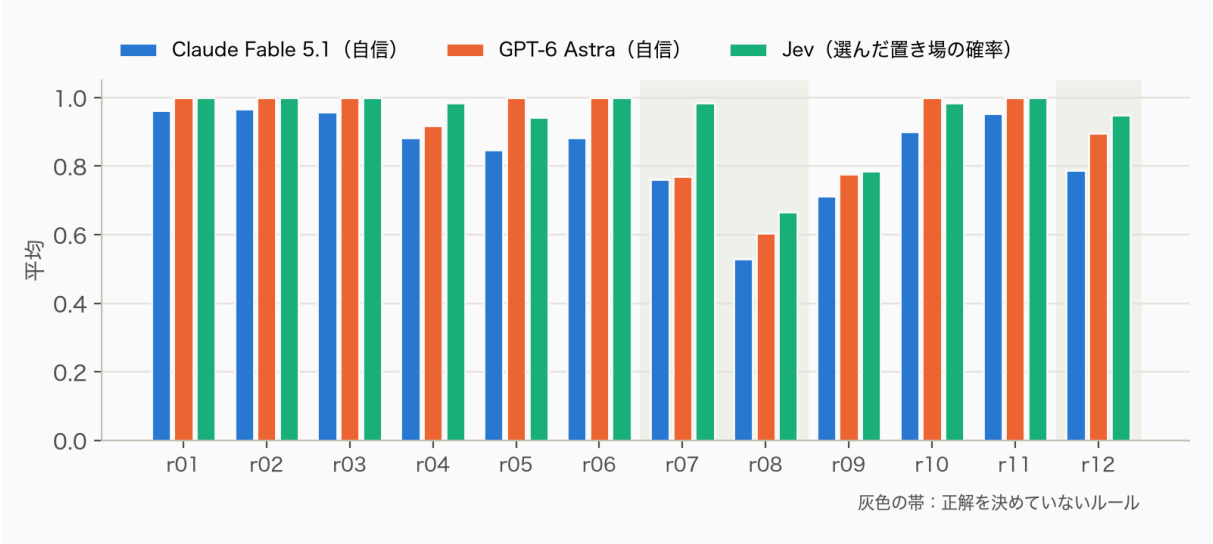
失敗のたびに安全策をコードに足した。 実機で起きた失敗ごとに、再発を防ぐ仕組みを入れた。

起きたこと	足した仕組み
掴みに行く途中で腕がカップを払った	物を持たない移動は、畳んだまま旋回してから伸ばす
離した後、開いた爪がカップに掛かり、カップごと運んだ	離した後に爪を閉じてから上へ抜く。置き場だけを物なしで試す `--test-bins`
方眼の点を縦横入れ替えて記録した	番号付きの地図を出す。記録後に関節角の並びを自動点検して警告する
土台が滑って、全部の姿勢がずれた	画像の固定物を比べて、何が動いたかを特定する手順を作った
左端の点で、爪がいつもカップ側に下りた	列ごとにずらす量を変えられるようにした
置き場に入らなくなった原因が分からなかった	置き場の単独試験で、下ろした所の関節角と指令との差を表示する

4. 実験1：ルール判断の一括評価

実機を動かさずに、撮影した9つの状態（物体1〜5個）に12ルールを当てはめ、各モデルに108回ずつ判断させた。正解は、ルール文から一つに決まる場合だけ決めた。ルールが想定していない色、境目に近い位置、矛盾や主観を含むルールは採点から外した。採点基準は evaluate.py に書いてある。

ルール	内容	正解（3モデル）	採点外	Fable 自信	Astra 自信	Jev 確率
r01	ピンクを含む物は左、他は右	27/27	0	0.96	1.00	1.00
r02	丸い物は中央、他は左	27/27	0	0.97	1.00	1.00
r03	黄は右、青は左、他は中央	27/27	0	0.96	1.00	1.00
r04	暖色は左、寒色は右	23/23	4	0.88	0.92	0.98
r05	机の下半分は中央、上半分は右	15/15	12	0.85	1.00	0.94
r06	2色以上は中央、単色の赤は左、他は右	27/27	0	0.88	1.00	1.00
r07	ピンクは左、丸い物は中央（矛盾）	採点外	27	0.76	0.77	0.98
r08	食べ物に見える物は右（主観）	採点外	27	0.53	0.60	0.67
r09	信号機の色に従う	15/15	12	0.71	0.78	0.79
r10	一番大きい物だけ右	9/9	18	0.90	1.00	0.98
r11	緑は中央、他は丸ければ左・角ばれば右	27/27	0	0.95	1.00	1.00
r12	左端に近い物ほど左（解釈が要る）	採点外	27	0.79	0.89	0.95



ルールごとの確からしさの平均。Fable と Astra は自分で申告した自信、Jev は選んだ置き場の確率

答えが決まる物では差がなかった。 3モデルとも 197 件すべて正解で、答えは一致した。

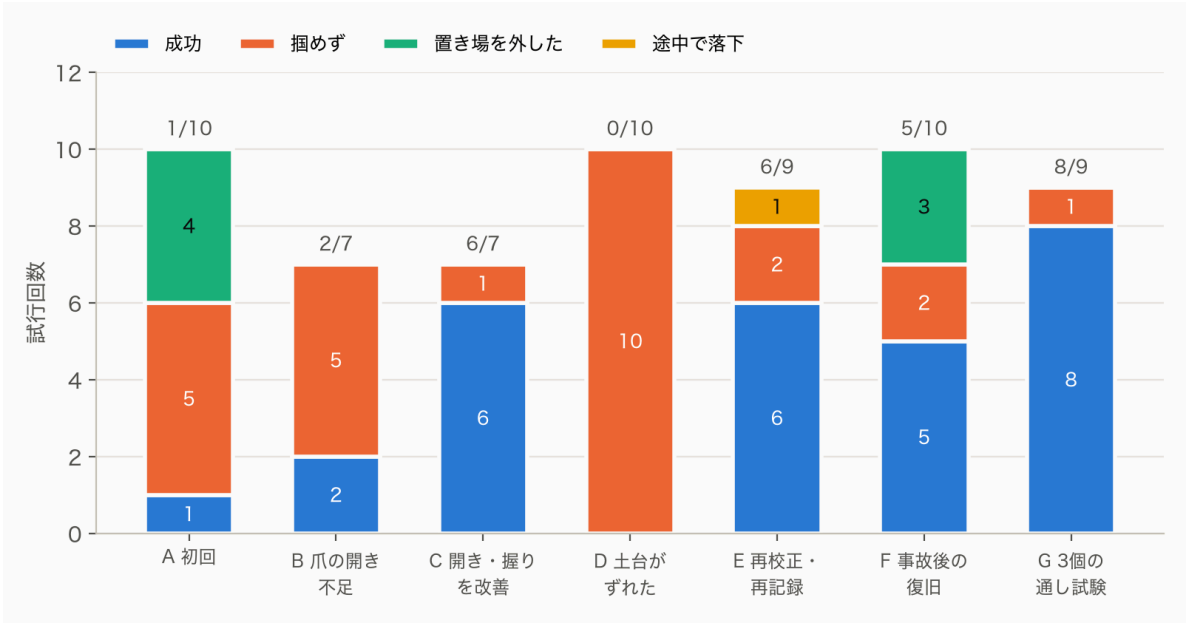
分かれたのは、答えが決まらない物だけだった。 324 個のうち置き場が分かれた数は、Fable と Astra で 12 個、Fable と Jev で 27 個、Astra と Jev で 27 個だった。すべて採点外の物である。Astra の判断は Fable に近く、Jev とは離れていた。

ルール	分かれ方
r09 信号機	ピンクを、Fable と Astra は8回とも信号機の「赤」（止まれ）とみなして左へ送った。Jev はそうせず、中央4・左2・右2 と割れた。黒は、Fable が左と右に半々、Astra が4回とも中央、Jev がほぼ左と、3つともばらばらだった
r08 食べ物	緑のアヒルを、Fable と Astra はほぼ「食べ物」として右へ、Jev は多く左へ送った。ピンクは3つとも左右に割れた
r05 境目	縦の中ほどにある物を、Fable と Astra は右、Jev は中央へ
r12 左端	真ん中付近の物の扱いが分かれた

確からしさの出し方が違った。 Jev は全体に高い値を返した。特に矛盾するルール r07 では、Fable と Astra の自信が 0.5〜0.6 に下がったのに対し、Jev はピンクで丸い物を確率 0.91〜0.98 で左へ送った。Fable と Astra はルール同士がぶつかっていることを値の低さで示したが、Jev は示さなかった。一方、境目の位置を問う r05 では、Astra は自信 1.00 のままで、Fable（0.85）ほど下げなかった。自信が下がる場面は、LLM どうしでも同じではない。Jev の確率は3つの置き場への分布として返るので、どの置き場で迷っているかまで見える。

なお Jev が返す confidence は、分布がどれだけ一つに偏っているかを表す値で、選んだ答えが正しい確率ではない。上の比較では、選んだ置き場の確率を使った。

5. 実験2：実機での仕分けの改善（Fable）



改善の段階ごとの試行結果（数字は成功数／試行数）。判断はすべて Fable

段階	成功	主な失敗の原因	対策
A 初回	1/10	方眼の点を縦横入れ替えて記録。置き場が低く、カップの縁に当たった	記録を直した。置き場の真上へ寄ってから下ろす
B 爪の開き不足	2/7	記録時の爪の開きがアヒルの幅とほぼ同じで、5mm ずれると爪が乗り上げた	近づくときだけ爪を大きく開く。記録値より深く握る
C 開き・握りを改善	6/7	下寄りの位置で、腕がカップに接触	畳んで旋回してから伸ばす
D 土台がずれた	0/10	接触で土台と紙が 2〜3cm 滑った。気づかずに記録をやり直して悪化した	画像の固定物と比べて原因を特定。土台と紙を固定
E 再校正・再記録	6/9	補正値で真ん中は合ったが、左右がずれた（土台が回転もしていた）	校正→姿勢の記録の順でやり直した
（事故）	–	開いた爪がカップに掛かり、カップごと運んで土台ごと崩れた	離した後に爪を閉じて抜く。`--test-bins`
F 事故後の復旧	5/10	置き場を爪の隙間の中心で合わせていたため、挟んだアヒルが固定側に寄った分だけ外れた	置き場はアヒルを挟んだ状態で記録する
G 3個の通し試験	8/9	方眼の端の物を掴めなかった	左端の狙いを直した（実験3）

62回の試行で、判断が原因の失敗はなかった。失敗はすべて、姿勢の記録、カメラの校正、土台の固定、爪の形のどれかだった。

6. 実験3：実機での比較（Fable・Astra・Jev）

実験2の最後の通し試験（10/25、段階 G）と同じルール・同じ並べ方で、11/1 に3つのモデルで運ばせた。並べ方は、方眼の真ん中の行の3点に1個ずつである。

比べる前に直したこと。 1週間空いたので、物を運ぶ前に変化を調べ、変えた所を単独で試してから進めた。

見つかったこと	対処	確かめ方
土台の板ごと、カメラから見て約 1cm 動いていた。机の外の物は動いていない	紙の四隅を前回の画像と照合し、校正だけを合わせ直した	四隅の一致度 0.96〜0.99
中央のカップ（置き場 11）で、爪がカップに触れた	下ろす高さを肩の角度で2度（約 8mm）上げた	`--test-bins` で触れずに抜けた
左端の点で、爪がアヒルよりカップ側に下りて掴めなかった	左端の列だけ、狙いをずらす量を 0.5cm から 1.2cm にした	把持確認で真上に下りた

左端の直し方は一度で決まらなかった。最初はずれの向きを逆に読み、狙いをカップ側へ動かして悪化させた。教えた点の外側へ狙いを延長する方法も試したが、延長した狙いはどちらもカップ側に外れた。結局、ずらす量を増やし、外側の物も左端の点を狙う形に落ち着いた。

運んだ順番。 午前に Jev で運びながら上のアームの調整をした。調整を終えた状態で、午後に Fable、続けて Jev の r01 と r09 を運んだ。その後、置き場 10 と 11 を記録し直してから（後述）、Astra で運んだ。表の Jev の r04 は、午前の調整後の回である。

結果。

ルール	物体（左から）	Fable	Astra	Jev
r01	ピンク・緑・黄	左・右・右　3/3	左・右・右　3/3	左・右・右　3/3
r09	緑・黄・ピンク	右・中央・**左**（自信 0.40）　3/3	右・中央・**左**（自信 0.55）　3/3	右・中央・**右**（確率 0.73）　3/3
r04	緑・ピンク・黄	右・左・左　3/3	右・左・左　3/3	右・左・左　3/3
判断の時間		4.0〜6.3 秒	5.4〜6.0 秒	0.17〜0.21 秒

判断は、答えが決まる物ですべて一致し、運んだ結果も3つとも 9/9 だった。

分かれたのは r09 のピンクだけだった。 信号機の色にないピンクを、Fable と Astra は信号機の「赤」（止まれ）とみなして左へ送った。Jev は赤とみなさず、右（進め）へ送った。どのモデルも確からしさは高くない。どのモデルも、別の回でも同じ置き場を選んだ。Fable は 10/25 にも左（自信 0.40）、Jev は午前にも右（確率 0.48）だった。Astra は一括評価で8回とも左だった。

アームの動きはモデルに依らない。 1個を運ぶ時間は、どのモデルでも 25〜30 秒だった。腕の通り道・速さ・加減速は共通のコードが決めているためで、モデルが決めるのは置き場だけである。10/25 の Fable（8/9）で掴めなかった左端の緑は、左端の狙いを直した後は、どのモデルでも掴めた。

同じ日の中でも、置き場が合わなくなった。 午後に Jev の r04 も取り直そうとしたところ、置き場 10（左のカップ）で外れる回が続いた。判定まで進んだ5回のうち4回で、ピンクか黄がカップの外に落ちた。それまでは、置き場 10 への運び込みは9回すべて成功していた。カメラの画像では、カップ・紙・机・アームの根元は動いていなかった。置き場に下ろした所で関節角を測ると、3つの置き場とも指令との差は同じで（肘が約 2 度、ほかは 0.5 度以内）、モーターは指令どおりに届いていた。原因は特定できていない。真上のカメラにも関節角にも映らない変化（モーターと腕の取り付けのわずかなずれ、カップの高さや傾き）と考えている。置き場 10 と 11 を記録し直すと単独試験が通り、Jev の r04 で3個とも入ることを確かめてから Astra に進んだ。このため、Astra だけは新しい置き場の姿勢で運んでいる。判断の比較には影響しない。

Jev では、ほかにも調整の途中で2回運んでおり、どちらも記録に残した。直す前の r01 は 2/3（左端のピンクが掴めず）、左端を直す途中の r04 は 1/3（左端の緑が掴めず、中央のピンクを途中で落とした）だった。

7. 考察

明確なルールでは、判断モデルを替えても結果は変わらなかった。 答えが決まる物では、一括評価でも実機でも3つのモデルは一致し、誤りはなかった。同じ日に運ばせると、運んだ結果も3つとも 9/9 だった。このシ

ステムで難しいのは言葉の解釈ではなく、カメラとアームと机の位置関係を保つことだった。この結論は vol.1 と同じで、モデルを替えても変わらなかった。

モデルの差は、曖昧な物の扱いに出た。 信号機の色にないピンクを「赤」とみなすか、食べ物かどうか、境目の位置で、置き場が分かれた。2つの LLM（Fable と Astra）は互いに近く、判断専用モデルの Jev は別の答えを選びやすかった。LLM はピンクを赤の仲間と読み替えてルールに当てはめにいき、Jev はそうしなかった、と言える。どちらが正しいとは言えないので、曖昧な物は運ばずに人に確認する運用が向く。そのためには、確からしさが曖昧さを正しく映している必要がある。

確からしさの意味がモデルごとに違う。 Fable と Astra の自信は、矛盾するルール（r07）で下がった。Jev の確率は全体に高く、矛盾には反応しなかった。一方で、境目の位置（r05）では Astra の自信は下がらなかった。Jev は3つの置き場への分布を返すので、どの置き場で迷っているかまで分かる。`--min-conf` のしきい値は、モデルごとに決め直す必要がある。

速さと費用では Jev が大きく上回った。 判断の時間は Fable と Astra の約 30 分の 1、費用は Fable の約 800 分の 1 だった。Astra は定額の利用枠で使えたが、Codex の前置きのために1回の入力が Jev の約 16 倍になった。このシステムでは、1個を運ぶのに 25〜30 秒かかるので、判断の 5 秒は全体を大きくは遅らせない。ただし、判断の回数が多い使い方や、待ち時間が目立つ使い方では差が効く。

位置合わせは時間がたつと崩れる。 1週間空いただけで、土台が 1cm 動き、中央のカップの高さが合わなくなっていた。本番の前に、固定物との画像比較、置き場の単独試験、把持確認の3つを挟んだので、物を運ぶ前に直せた。同じ日の中でも、数時間動かした後に置き場 10 が合わなくなった。教えた姿勢をそのまま再生する方式は、こうした変化を自分では検出できない。置いた結果をカメラで確かめる仕組みが要る。

言葉での位置の伝え方に落とし穴があった。 左端の調整では、「やや左寄り」という報告を、座っている位置から見た左右（カメラ画像と鏡写し）だと決めつけて、逆向きに直した。近くのカップを目印に聞き直して、正しい向きが分かった。

8. AI の使い方

- **判断（Fable）**：Claude Fable 5.1 を、Claude Code のヘッドレス実行（`claude -p`）で呼んだ。ツールは使わせず、JSON スキーマで出力形式を固定した。
- **判断（Astra）**：GPT-6 Astra を、Codex CLI のヘッドレス実行（`codex exec`）で呼んだ。読み取り専用で、JSON スキーマで出力形式を固定した。
- **判断（Jev）**：TypeSafe の System One API に、物体ごとの選択式の質問として送った。
- **開発**：コードの作成、失敗の原因調査（画像の比較など）、集計、動画の編集に Claude Code を使った。

9. 今後

- 動かしている最中の関節角を記録し、速さ・振動・目標との誤差を測る。モデルに依らずアームの動きが同じことを、データで示せる
- 置いた結果をカメラで確かめ、置き場のずれを自分で検出する
- 確からしさのしきい値をモデルごとに決め、曖昧な物を人に確認する運用を試す
- 逆運動学で姿勢を計算し、教える手間と位置合わせの誤差を減らす

付録：再現手順

```
python calibrate.py --points <四隅>      # カメラと机の対応づけ
python teach.py --test-bins             # 置き場を物なしで試す（指令との差も表示）
python check_grasp.py                    # 掴む位置を物 1 個で確かめる
python decide.py runs/<日付>/states.jsonl --backend astra   # 判断の一括評価（fable / astra / jev）
python sort.py --rule r01 --backend jev --step --judge      # 実機で仕分け
python evaluate.py                       # 集計（判断先ごと、分かれた物の一覧）
```

Jev を使うには、TypeSafe の API キーを環境変数 `TYPESAFE_API_KEY` か `keys.env` に置く。Astra は Codex CLI にログインしたアカウントで呼ぶ。

動画の BGM：CMSL クラシック名曲サウンドライブラリー「ラストシンフォニー」のライセンスフリー素材音源（チャイコフスキー「白鳥の湖」第2幕 情景、https://classical-sound.seesaa.net/article/464440694.html）